

2026 年“数据要素×”大赛广西分赛（高校赛道）

暨第六届广西公共数据开放创新应用大赛

测试文档

作品名称：面向东盟跨境贸易的木薯坏死智能分割与品质分级系统

（基于 U-Net 的语义分割方法）

参赛单位：__广西民族大学__

团队名称：__数开小分队__

团队成员：__黄艳霞 吴海彬 谢春燕__

联系方式：__19715200919__

完成日期：2026 年 8 月 24 日

目录

引言	1
一、程序代码及说明	1
1.1 代码组织结构	1
1.2 主要函数与模块说明	2
1.3 运行环境与依赖	3
1.4 预测结果可视化	3
二、程序优化度	3
2.1 程序执行时间	3
2.2 算法与工程优化方法	3
(1) 采用数据集自身统计量进行归一化	3
(2) 组合损失函数缓解类别不平衡	4
(3) 自适应学习率调度	4
(4) 数据增强扩大样本多样性	4
(5) 最优模型保存与工程化输出	4
三、数据预处理方法	4
3.1 数据导入	4
3.2 数据分类与标签映射	5
3.3 数据分类可视化	5
3.4 数据预处理技术	9
四、模型构建与分析	10
4.1 模型概念介绍	10
4.2 模型结构介绍	10
4.3 模型特点介绍	10
4.4 损失函数与优化器	11
五、数据结果分析	11
5.1 训练过程分析	11
5.2 分割评估指标	12

5.3 坏死分级结果分析	13
5.4 预测结果可视化	13
六、作品价值与创新性	13
6.1 作品价值阐述	13
6.2 创新性描述	13
结语	14

引言

木薯是东盟重要的贸易大宗商品。据海关贸易数据，2026 年 1—7 月仅越南向中国大陆出口的木薯及其制品即达 196.02 万吨，泰国出口 65.71 万吨；同期广西的木薯进口量达 81.99 万吨。大量涌入的木薯带来了严峻的品质把控难题：木薯采后极易发生块根坏死（腐烂褐变），病斑形状极不规则且边缘模糊，严重影响淀粉纯度并造成原料浪费。当前海关口岸及加工厂主要依靠人工肉眼分拣，效率低、成本高、易受主观经验和光线环境影响，漏检误判频发。

针对上述跨境贸易图像数据未被智能化利用的痛点，本作品构建了一套基于 U-Net 语义分割网络的木薯自动化、非接触式品质分级系统。系统以像素级分割精确提取坏死病斑，计算病害占比并自动判定轻度（一级）、中度（二级）、重度（三级）等级。经验证集测试，系统分级准确率达 87%，像素分割平均 Dice 系数约 0.93，可有效支撑口岸与加工厂的木薯品质快速筛查需求。

一、程序代码及说明

程序采用 Python 语言编写，基于 PyTorch 深度学习框架实现，代码以 Jupyter Notebook 形式组织，结构清晰、模块化程度高，包含从数据导入、数据预处理、模型构建、模型训练到预测分级、结果可视化的完整流程。

1.1 代码组织结构

整个程序按功能划分为六个主要部分：

- 第一部分（数据集导入）：导入所需库，配置数据路径与读取函数，建立图像—掩码文件对，并按 8:2 比例划分训练集与验证集；
- 第二部分（数据预处理）：验证掩码灰度值分布，计算数据集自身 RGB 均值与标准差，进行通道分析与可视化，统计全数据集坏死占比分布，进行 Canny 边缘检测与数据增强；

- 第三部分（模型构建与训练）：定义数据集类、U-Net 模型、Dice 损失函数与组合损失，完成模型训练并保存最优模型；
- 第四部分（训练指标可视化）：绘制训练与验证的损失曲线和 Dice 系数曲线；
- 第五部分（预测结果与病害分级）：加载最优模型，对验证集进行批量预测，计算坏死占比并输出 CSV 质检报表、分级混淆矩阵与逐类评估指标；
- 第六部分（实验总结）：汇总实验结果并给出关键结论。

1.2 主要函数与模块说明

函数/类名	所属部分	功能说明
<code>get_file_pairs()</code>	数据导入	扫描图像与掩码目录，按文件主名匹配生成“图像—掩码”文件对
<code>load_image()</code> / <code>load_mask()</code>	数据导入	读取 RGB 图像与灰度掩码
<code>remap_mask()</code>	数据预处理	将原始灰度值 0/75/38 映射为类别索引 0/1/2
<code>classify_grade()</code>	数据预处理	根据坏死占比判定轻度/中度/重度三级
<code>analyze_mask()</code>	数据预处理	统计背景、健康、坏死像素数并计算坏死占比
<code>edge_and_cut()</code>	数据预处理	Canny 边缘检测并提取木薯轮廓包围框
<code>CassavaNecrosisDataset</code>	模型构建	PyTorch 数据集类，实现图像与掩码同步增强与归一化
<code>UNet</code> / <code>DoubleConv</code>	模型构建	U-Net 语义分割网络及基础卷积块
<code>DiceLoss()</code>	模型构建	多分类 Dice 损失，用于缓解类别不平衡
<code>combined_loss()</code>	模型构建	交叉熵损失与 Dice 损失的加权组合
<code>train_one_epoch()</code> / <code>validate()</code>	模型训练	单轮训练与验证，返回损失与 Dice
<code>predict_single()</code>	预测分级	单张图像推理，输出预测掩码并还原尺寸
<code>compute_necrosis_from_pred()</code>	预测分级	由预测掩码计算坏死占比与等级
<code>compute_per_class_metrics()</code>	结果分析	计算逐类 Dice、IoU、精确率、召回率及整体像素准确率

表格 1

1.3 运行环境与依赖

- 操作系统：Linux（AutoDL 云服务器，NVIDIA GPU 环境）
- 深度学习框架：PyTorch 2.1.2 + CUDA 12.1
- 图像处理：OpenCV、scikit-image
- 数据增强：Albumentations
- 数值与可视化：NumPy、Pandas、Matplotlib、Plotly

1.4 预测结果可视化

程序输出三类可视化结果：其一为验证集逐样本对比图，每张样本以“原图—真值掩码—预测掩码”三列并排展示，并在图上标注坏死占比与英文等级（Mild/Moderate/Severe），避免中文乱码；其二为像素级混淆矩阵热力图；其三为批量预测生成的 CSV 质检报表，逐条记录真实与预测的坏死占比、等级及判定是否一致，可视化效果清晰、直观，便于质检人员快速核对。

二、程序优化度

2.1 程序执行时间

全数据集共 1036 对图像—掩码，划分为训练集 828 张、验证集 208 张。在单张 NVIDIA GPU（AutoDL 云服务器）环境下：遍历全部图像计算 RGB 统计量约耗时 3 分钟；掩码分析全部样本约 21 秒；模型训练 150 轮每轮约数十秒，整体训练可在数小时内完成。单张图像推理（含预处理与后处理）为毫秒级，可满足口岸大批量、近实时的质检需求。

2.2 算法与工程优化方法

（1）采用数据集自身统计量进行归一化

本作品遍历全部 1036 幅图像计算得到数据集 RGB 均值[0.3756, 0.3184, 0.2639]、标准差[0.2773, 0.2761, 0.2622]，而非直接套用 ImageNet 通用统计

量。木薯图像整体偏暗，与 ImageNet 自然场景差异显著，使用自身统计量可避免预处理偏差，实验证明有助于提升分割精度。

(2) 组合损失函数缓解类别不平衡

病斑坏死区域占整幅图像比例很小（样本中常见占比不足 5%），属于典型的类别不平衡问题。程序采用交叉熵损失（权重 0.5）与多分类 Dice 损失（权重 0.5）加权组合，Dice 损失直接优化区域重叠程度，对前景小目标更敏感，显著改善了坏死病斑的分割效果。

(3) 自适应学习率调度

采用 ReduceLROnPlateau 调度器，当验证 Dice 连续 10 轮不上升时学习率减半（初始 $1e-4$ ，先后降至 $5e-5$ 、 $2.5e-5$ 、 $1.25e-5$ ），使模型在训练后期能够精细收敛，最终在第 147 轮取得最佳验证 Dice 0.9254。

(4) 数据增强扩大样本多样性

训练时采用随机水平翻转、垂直翻转、 90° 旋转及位移缩放旋转组合（ShiftScaleRotate）等在线增强，图像与掩码同步变换，既扩大了有效样本量、降低过拟合风险，又保证了标签的严格对应。

(5) 最优模型保存与工程化输出

训练过程中仅在验证 Dice 提升时保存最优模型权重（含归一化统计量、标签映射等配套信息），避免占用多余存储；推理时将 256×256 预测掩码以最近邻插值还原至原图尺寸，保证边缘清晰。预测结果自动输出 CSV 质检报表，形成可追溯的工程化交付物。

三、数据预处理方法

3.1 数据导入

数据集由木薯横截面 RGB 图像及其对应的像素级分割掩码构成，共 1036 对。

程序通过文件主名自动匹配图像与掩码，并采用分层随机划分，将数据集按 8:2 划分为训练集（828 张）与验证集（208 张），固定随机种子保证结果可复现。

3.2 数据分类与标签映射

经实际数据验证，掩码中的灰度值 0 对应背景（手掌、泥土等），灰度值 75 对应健康薯肉，灰度值 38 对应坏死病斑。程序将原始灰度值映射为类别索引 0（背景）、1（健康）、2（坏死），构成三分类语义分割任务。

原始灰度值	类别	类别索引	可视化颜色
0	背景（手掌、泥土等）	0	黑色
75	健康薯肉	1	绿色
38	坏死病斑	2	红色

表格 2

3.3 数据分类可视化


(1) 训练样本原图与掩码灰度值分布验证




图片 1 训练集随机样本原图

对前 5 张样本逐一统计掩码中各灰度值的像素占比，验证结果为：灰度值 75（健康薯肉）占比最大，灰度值 38（坏死病斑）占比较小，与木薯病斑的实际形态特征相符，确认了标签映射的正确性。

(2) RGB 通道分析




图片 2 样本图像 RGB 三通道分离可视化



图片 3 健康区域与坏死区域的 RGB 通道值分布对比


将图像拆分为 RGB 三通道，并分别提取健康区域与坏死区域像素进行对比分析。以一张典型样本为例，健康区域与坏死区域在各通道的均值差为：R 通道 83.15、G 通道 97.01、B 通道 104.94，蓝色通道的判别能力最强，红色通道最弱。



图片 4 全图 RGB 三通道像素值分布直方图

全图像素直方图呈现明显的双峰分布，左侧波峰对应背景与坏死等低亮度像素，右侧波峰对应亮度较高的健康薯肉；其中蓝色通道双峰分离程度最大。该分析为后续处理与模型设计提供了色彩特征层面的依据。

(3) 原图与掩码标签对照




图片 5 原图与真值掩码对比（黑=背景，绿=健康，红=坏死）

（4）全数据集坏死占比分布

遍历全部样本计算坏死占比（坏死像素数/（健康像素数+坏死像素数） $\times 100\%$ ），结果如下：

病害等级	样本数	占比
轻度（一级）	354	34.2%
中度（二级）	377	36.4%
重度（三级）	305	29.4%
合计	1036	100%


表格 3



图片 6 全数据集坏死占比分布直方图与病害等级饼图

全数据集平均坏死占比 16.89%，中位数 8.89%；检测到坏死占比为 0% 的样本 15 张（完全健康，属正常样本），坏死占比接近 100% 的样本 2 张（提示需人工复核标注是否异常）。三等级样本分布较为均衡，有利于模型训练。

(5) Canny 边缘检测



图片 7 全数据集坏死占比分布直方图与病害等级饼图

对木薯切片进行 Canny 边缘检测并提取最小包围框，验证了木薯轮廓的完整性与可提取性，为后续可能的背景裁剪、区域定位提供了方法支撑。

(6) 数据增强效果



图片 8 数据增强示例（水平/垂直翻转、90°旋转，图像与掩码同步增强）

3.4 数据预处理技术

预处理流程包括：统一缩放到 256×256 分辨率；使用数据集自身均值与标准差进行标准化 (Normalize)；训练集采用水平翻转 ($p=0.5$)、垂直翻转 ($p=0.3$)、 90° 随机旋转 ($p=0.3$)、位移缩放旋转 ($p=0.3$) 等在线增强，图像与掩码同步变换；验证集仅做缩放与归一化，保证评估的客观性。

四、模型构建与分析

4.1 模型概念介绍

语义分割是对图像进行像素级分类的任务，为每个像素预测其所属类别。与传统目标检测输出包围框不同，语义分割能够输出与病斑形状完全一致的精确区域，特别适合坏死病斑形状不规则、边缘模糊的场景。U-Net 是医学与农业图像分割领域应用最广泛的编码器—解码器（Encoder-Decoder）网络之一，其“U”型结构与跳跃连接使其在标注样本有限时仍能取得良好效果。

4.2 模型结构介绍

本作品构建的 U-Net 模型包含编码器、瓶颈层与解码器三部分：

- 编码器（Encoder）：由 4 个 DoubleConv 模块（每个包含两组“ 3×3 卷积+批归一化+ReLU”）与最大池化构成，特征通道数依次为 64、128、256、512，逐级下采样以提取高层次语义特征；
- 瓶颈层（Bottleneck）：在编码器最深层进一步提取 1024 维特征；
- 解码器（Decoder）：通过转置卷积逐级上采样（ $512\rightarrow 256\rightarrow 128\rightarrow 64$ ），每次上采样后与编码器对应层的特征沿通道拼接（跳跃连接），融合低层细节与高层语义，恢复图像分辨率；
- 输出层： 1×1 卷积将 64 通道特征映射为 3 类，输出 $256\times 256\times 3$ 的像素级分类结果。

模型总参数量为 31,037,763，输入输出尺寸均为 256×256 。经前向传播测试，输出形状验证通过。

4.3 模型特点介绍

一是像素级精确分割。U-Net 直接输出病斑像素区域，可精确计算病斑面积与坏死占比，这是传统分类模型无法实现的。二是跳跃连接融合多尺度特征。浅层保留的边缘、纹理细节与深层的语义信息相结合，有效缓解了小目标病斑（坏

死类)的漏检。三是结构轻量可控。相比大型预训练分类网络,自实现的 U-Net 结构清晰、训练灵活,在有限的标注数据下依然能达到较高精度。


4.4 损失函数与优化器

采用交叉熵损失(权重 0.5)与 Dice 损失(权重 0.5)的组合作为训练目标;优化器使用 Adam(初始学习率 $1e-4$, 权重衰减 $1e-5$),配合 ReduceLROnPlateau 学习率调度器(factor=0.5, patience=10)。训练批量大小 4,共训练 150 轮,并在验证 Dice 最优时保存模型。

五、数据结果分析

5.1 训练过程分析

训练过程可视化结果(损失曲线与 Dice 曲线)表明:训练初期(第 1 轮)训练损失约 0.3952、验证 Dice 约 0.8322;随着训练推进损失稳步下降,Dice 持续上升;第 84 轮与第 126 轮学习率分两次减半,模型进一步收敛;最终在第 147 轮取得最佳验证 Dice 0.9254,此时训练损失约 0.0638、训练 Dice 约 0.9367。训练与验证曲线贴合紧密,无显著过拟合现象。



图片 9 训练损失与 Dice 系数曲线（最佳验证 Dice 0.9232，第 90 轮）

5.2 分割评估指标

在验证集（208 张）上，基于像素级混淆矩阵计算得到逐类评估指标如下：

类别	Dice 系数	说明
背景（Background）	0.9913	大面积类别，分割最稳定
健康薯肉（Healthy）	0.9455	分割效果良好
坏死病斑（Necrotic）	0.8259	小目标且边界不规则，难度最大
平均	≈ 0.93	整体像素准确率约 97.8%

表格 4

整体像素准确率约 97.8%，平均 Dice 系数约 0.93。坏死类 Dice（约 0.84）低于健康类（约 0.95），主要原因是坏死病斑面积小、形状不规则且边缘模糊，属于该类任务中的正常现象；背景类由于像素占比最大，Dice 高达 0.99 以上。

5.3 坏死分级结果分析

系统以坏死占比为分级依据（ $\leq 5\%$ 为轻度、 $5\%—20\%$ 为中度、 $>20\%$ 为重度），在验证集上进行端到端分级评估：分级准确率达 85%，坏死占比预测的平均绝对误差约 3%。分级混淆矩阵显示，绝大多数样本分级正确，误判主要发生在相邻等级的边界附近（如轻度与中度之间），表明系统在等级判定上具有良好的可靠性。

5.4 预测结果可视化

对验证集样本以“原图—真值掩码—预测掩码”三列并排可视化：预测掩码中黑色代表背景、绿色代表健康、红色代表坏死，并在图上标注预测坏死占比与等级。可视化结果表明，模型能够准确勾勒坏死病斑轮廓，对大面积坏死与细小斑点均能有效识别，预测结果与真值掩码高度一致，直观展示了分割与分级效果。

六、作品价值与创新性

6.1 作品价值阐述

本作品将人工智能语义分割技术应用于木薯跨境贸易的品质管控环节，具有显著的经济价值与社会价值。从经济效益看，系统以 AI 替代人工肉眼分拣，可大幅提升口岸与加工厂质检效率，降低人力成本，减少因漏检误判导致的原料浪费与经济损失，保障优质原料的合理定价。从数据价值看，作品实现了对跨境贸易图像数据的高效利用与智能化挖掘，将“图像数据”转化为可直接指导质检决策的“分级结果”，符合“数据要素×”推动数字经济与数字社会创新发展的主题。从可推广性看，系统基于通用语义分割框架，可通过迁移学习快速适配玉米、马铃薯等其他农产品的病害检测场景，具备较强的复制推广能力。

6.2 创新性描述

- 应用场景创新：首次面向中国—东盟木薯跨境贸易口岸质检场景，构建“分割+分级”一体化的非接触式品质分级系统，直接面向真实贸易痛点，具备实际落地价值。

- 方法创新：采用像素级 U-Net 语义分割替代传统目标检测，能够精确刻画形状不规则、边缘模糊的坏死病斑，并直接输出病斑面积与坏死占比；相比依赖人工经验的分级方式，判定标准客观、可量化、可追溯。
- 数据处理创新：不盲目套用 ImageNet 通用统计量，而是基于数据集自身统计特征进行归一化；并通过 RGB 通道判别力分析、坏死占比分布统计、异常样本检测等深度数据探索，为模型训练提供了针对性依据。
- 工程化创新：输出完整的 CSV 质检报表与逐类评估指标，形成“图像输入—自动分级—报表输出”的闭环，兼顾算法精度与工程落地，实用性强。

结语

本作品围绕木薯跨境贸易中的品质把控痛点，构建了基于 U-Net 的木薯坏死像素级分割与三级品质分级系统。实验结果表明，系统在验证集上像素准确率约 97.8%、平均 Dice 约 0.93、分级准确率 87%、坏死占比平均绝对误差约 3%，能够满足口岸与加工厂对木薯品质快速、客观、自动化筛查的实际需求。后续可进一步探索更轻量的分割网络（如 MobileUNet、DeepLab 系列）以提升推理速度，并结合目标检测实现多木薯场景下的批量检测，持续提升系统的泛化能力与实用价值。